

F-VICE: Forecasting Velocity of Ice in Glaciers Using Machine Learning

Rodrigo S. Cortez Madrigal^{**}
rcortez@enesmorelia.unam.mx
PCIC
CDMX, México

Luis V. Ruiz Hernández^{***}
lruiz@ciencias.unam.mx
PCIC
CDMX, México



Figura 1: Seattle Mariners at Spring Training, 2010.

Resumen

El deshielo de los glaciares es un fenómeno natural que ha aumentado en las últimas décadas debido al cambio climático. Este proceso tiene un impacto significativo en el nivel del mar y en los ecosistemas locales. En este trabajo, proponemos un enfoque basado en aprendizaje automático para predecir la serie de tiempo de la velocidad de deshielo de los glaciares. Utilizamos un conjunto de datos del proyecto *ITSLIVE* (Time Series of Land Ice Velocity and Elevation) del Jet Propulsion Laboratory de la NASA, que a partir de imágenes satelitales, proporciona información sobre la velocidad de deshielo de los glaciares. Finalmente comparamos los resultados de distintos modelos de aprendizaje automático y discutimos los resultados obtenidos.

CCS Concepts

• **Do Not Use This Code → Generate the Correct Terms for Your Paper;** *Generate the Correct Terms for*

^{*}Both authors contributed equally to this research.

^{**}Both authors contributed equally to this research.

Unpublished working draft. Not for distribution.

Permission to make digital or hard copies of all or part of this work for personal or internal use, or the internal or personal use of specific clients, is granted by ACM for libraries and registered users, provided that the fee of \$12.00 is paid directly to ACM. This fee code for users of the ACM Copyright Clearance Center (CCC) Transactional Reporting Service is 0001-5874/2025/05-31 16:07. Page 1 of 1-4.

PCIC: ML '25, Ciudad de México, México

© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 978-1-4503-XXXX-X/2025/06

<https://doi.org/XXXXXXX.XXXXXXX>

2025-05-31 16:07. Page 1 of 1-4.

Your Paper; Generate the Correct Terms for Your Paper;
Generate the Correct Terms for Your Paper.

Palabras claves

Do, Not, Us, This, Code, Put, the, Correct, Terms, for, Your, Paper

ACM Reference Format:

Rodrigo S. Cortez Madrigal and Luis V. Ruiz Hernández. 2025. F-VICE: Forecasting Velocity of Ice in Glaciers Using Machine Learning. In *Proceedings of Aprendizaje de Máquina (PCIC: ML '25)*. ACM, New York, NY, USA, 4 pages. <https://doi.org/XXXXXXX.XXXXXXX>

1 Introduction

La predicción de series de tiempo es una tarea importante en el ámbito del aprendizaje automático y la ciencia de datos. Desde la predicción de precios de acciones hasta la predicción del clima, las series de tiempo son una herramienta valiosa para la toma de decisiones y la planificación. No obstante, el estudio de series de tiempo en el contexto de los glaciares es un tema menos explorado.

El deshielo de los glaciares es un fenómeno natural que ha aumentado en las últimas décadas debido al cambio climático. Este proceso tiene un impacto significativo en el nivel del mar y en los ecosistemas locales. Por lo tanto, es crucial comprender, analizar y predecir la velocidad de deshielo de los glaciares para mitigar sus efectos negativos. En este contexto, la modelación de series de tiempo se convierte en una herramienta esencial para predecir la velocidad de deshielo de los glaciares. No obstante, para comprender plenamente cómo responden los glaciares al cambio medioambiental se necesitarán nuevos métodos que nos ayuden a identificar el

inicio de los fenómenos de aceleración del hielo y a observar cómo se propagan las señales dinámicas dentro de los glaciares [3].

En ese sentido, la velocidad de los glaciares es un parámetro importante que nos permite comprender el comportamiento dinámico de los glaciares y su respuesta al cambio climático [5]. Estudiar la velocidad de los glaciares es crucial para comprender cómo responden al cambio climático y cómo afectan al nivel del mar.

En este trabajo, proponemos un enfoque basado en aprendizaje automático para predecir la serie de tiempo de la velocidad de deshielo de los glaciares. Utilizamos un conjunto de datos del proyecto *ITSLIVE* (Time Series of Land Ice Velocity and Elevation) del Jet Propulsion Laboratory de la NASA, que a partir de imágenes satelitales, proporciona información sobre la velocidad de deshielo de los glaciares. Compararemos los resultados de distintos modelos de aprendizaje automático y discutiremos los resultados obtenidos.

2 Antecedentes

Durante la última década, el número de observaciones por satélite disponibles ha aumentado considerablemente, lo que ha permitido realizar mediciones mucho más frecuentes de la velocidad de los glaciares. Proyectos como el de Intermission Time Series of Land Ice Velocity and Elevation (*ITSLIVE*) de la NASA aceleran la comprensión de los procesos críticos de los glaciares y las capas de hielo proporcionando a la comunidad científica registros globales, de baja latencia, exhaustivos y de última generación de las velocidades y elevaciones de la superficie observadas desde el espacio [4].

Estos datos por lo tanto permiten a través de la modelación de series de tiempo, predecir la velocidad de los glaciares y su evolución en el tiempo.

Trabajos como el de derkacheva [2] han utilizado métodos como Lowess para el estudio de estas series de tiempo, mientras que anteriormente ya se habían utilizado modelos de regresión lineal y modelos ARIMA para la predicción de series de tiempo [1] sobre otros conjuntos de datos no *ITSLIVE*.

3 Metodología

Para la predicción de la velocidad de los glaciares, utilizamos el conjunto de datos del proyecto *ITSLIVE* de la NASA. Este conjunto de datos contiene información sobre la velocidad de deshielo de los glaciares a partir de imágenes satelitales.

Cada observación de velocidad de deshielo de los glaciares se registra en un intervalo de tiempo específico, lo que nos permite construir una serie de tiempo. Para la modelación de series de tiempo, utilizamos distintos modelos de aprendizaje automático, incluyendo modelos de regresión lineal, modelos ARIMA y redes neuronales recurrentes (RNN).

3.1 Conjunto de Datos

El conjunto de datos incluye 9 glaciares y cada uno de estos tiene asociado a un `DataFrame` con las siguientes variables:

- **mid_date**: Fecha media entre las dos imágenes usadas para calcular la velocidad.
- **v**: (Variable respuesta) Velocidad total de flujo (magnitud vectorial de vx y vy).
- **v_error**: Error estimado en la velocidad total v.
- **vx**: Componente de velocidad en el eje X (este-oeste).
- **vx_error**: Error en la componente de velocidad vx.
- **vy**: Componente de velocidad en el eje Y (norte-sur).
- **vy_error**: Error en la componente de velocidad vy.
- **date_dt**: Fecha de adquisición como objeto `datetime` completo.
- **satellite_img1**: Nombre o código del primer satélite usado para la imagen base.
- **mission_img1**: Misión satelital de la primera imagen.
- **x**: Coordenada X en proyección UTM u otra proyección local (EPSG específica).
- **y**: Coordenada Y en proyección UTM u otra.
- **lat**: Latitud geográfica del píxel o punto.
- **lon**: Longitud geográfica del píxel o punto.
- **year**: Año de la observación (extraído de *mid_date*).
- **month**: Mes de la observación (extraído de *mid_date*).
- **dayofyear**: Día del año (1 a 366).

3.2 Línea Base

Para establecer una línea base para la predicción de la velocidad de los glaciares, utilizamos un modelo de regresión lineal simple. Este modelo se basa en la suposición de que la velocidad de deshielo de los glaciares sigue una tendencia lineal a lo largo del tiempo. El modelo de regresión lineal se ajusta a los datos de velocidad de deshielo de los glaciares y se utiliza para predecir la velocidad futura.

Además de su simplicidad, la regresión lineal permite interpretar fácilmente la relación entre el tiempo y la velocidad del glaciar mediante sus coeficientes. El término de pendiente indica si la velocidad de flujo del glaciar está aumentando o disminuyendo con el tiempo, lo que puede ser un indicio de aceleración del deshielo por efectos climáticos. Aunque este modelo no captura patrones estacionales ni fluctuaciones no lineales, sirve como un punto de comparación robusto frente a modelos más complejos como XGBoost o ARIMA, y permite establecer una primera hipótesis sobre la evolución temporal del comportamiento glaciar.

3.3 ARIMA

El modelo ARIMA (Autoregressive Integrated Moving Average) es un modelo de series de tiempo que combina componentes autorregresivos, de media móvil e integración. El modelo ARIMA se utiliza para modelar series de tiempo estacionarias y no estacionarias. Para aplicar el modelo ARIMA a la serie de tiempo de la velocidad de deshielo de los glaciares, primero es necesario transformar la serie de tiempo en una serie estacionaria. Para ello, se aplican técnicas de diferenciación.

Una vez que se logra la estacionariedad mediante la diferenciación, el modelo ARIMA puede identificar y capturar patrones temporales en la serie, como la dependencia entre

observaciones pasadas (componente autorregresiva, AR) y los errores de predicción previos (componente de media móvil, MA). En nuestro caso, se ajustó un modelo ARIMA a la serie temporal de velocidades de deshielo utilizando la fecha como índice temporal.

3.4 XGBoost

XGBoost (Extreme Gradient Boosting) es un algoritmo de aprendizaje automático basado en árboles de decisión que se ha utilizado con éxito en diversas tareas de predicción. XGBoost es un algoritmo de boosting que combina múltiples árboles de decisión para mejorar la precisión de las predicciones. Se ha utilizado en diversas aplicaciones, incluida la predicción de series de tiempo.

En el contexto de series de tiempo, aunque XGBoost no modela explícitamente la dependencia temporal como los modelos clásicos (por ejemplo, ARIMA), puede adaptarse para tareas de predicción temporal al incorporar variables que representen el tiempo, como el año, mes, día del año o rezagos de la variable objetivo. Su capacidad para capturar relaciones no lineales y manejar grandes volúmenes de datos lo convierte en una herramienta eficaz cuando se dispone de múltiples variables explicativas o características derivadas del tiempo. Además, XGBoost incluye mecanismos de regularización, lo que resulta útil cuando se trabaja con conjuntos de datos ruidosos.

3.5 LSTM

Las redes neuronales recurrentes (RNN) son un tipo de modelo de aprendizaje automático que se utiliza para procesar datos secuenciales, como series de tiempo. Las RNN son capaces de capturar patrones temporales en los datos y se han utilizado con éxito en diversas aplicaciones, incluida la predicción de series de tiempo. En este trabajo, utilizamos una variante de las RNN llamada LSTM (Long Short-Term Memory), que es especialmente eficaz para modelar dependencias a largo plazo en los datos.

Las redes LSTM superan una de las principales limitaciones de las RNN tradicionales: el problema del desvanecimiento o explosión del gradiente durante el entrenamiento. Gracias a su arquitectura con compuertas de entrada, olvido y salida, las LSTM pueden retener información relevante durante períodos más largos y descartar información irrelevante, lo que las hace particularmente adecuadas para modelar series de tiempo con comportamientos complejos o retardos significativos en sus patrones. En este proyecto, el modelo LSTM se alimenta con secuencias históricas de velocidad del glaciar para realizar predicciones más precisas del comportamiento futuro.

3.6 Compración de Resultados

Para comparar los resultados de los distintos modelos de aprendizaje automático, utilizamos métricas de evaluación que describiremos en la siguiente subsección. Además del desempeño de los modelos, también consideramos la interpretabilidad y la complejidad de cada modelo. Este análisis

comparativo nos permitirá comparar sistemáticamente el desempeño de los modelos y discutir sus fortalezas y debilidades para este problema en específico.

3.6.1 Métricas. Para evaluar el rendimiento de los modelos de aprendizaje automático, utilizamos métricas de evaluación como el error cuadrático medio (MSE) y el coeficiente de determinación (R^2).

- El error cuadrático medio (MSE) es una métrica que mide la diferencia entre los valores predichos por el modelo y los valores reales de la variable objetivo. El MSE se calcula como la media de los cuadrados de las diferencias entre los valores predichos y los valores reales. Elegimos el MSE para este problema en específico porque en el contexto de la predicción de series de tiempo, es importante minimizar los errores grandes para obtener predicciones más precisas.
- El coeficiente de determinación (R^2) es una métrica que mide la proporción de la varianza de la variable objetivo que es explicada por el modelo. El R^2 se calcula como la proporción de la varianza de los valores predichos que es explicada por la varianza de los valores reales. Es útil porque nos permite evaluar la capacidad del modelo para explicar la variabilidad de los datos.

4 Experimentos y Resultados

Para evaluar el rendimiento de los modelos de aprendizaje automático, realizamos una serie de experimentos utilizando el conjunto de datos del proyecto *ITSLIVE* de la NASA. Seleccionamos un subconjunto de glaciares importantes y obtuvimos las series de tiempo de la velocidad de deshielo de estos glaciares. El conjunto de datos se dividió en un conjunto de entrenamiento y un conjunto de prueba en un porcentaje de 70 % para entrenamiento y 30 % para prueba. Esto debido a que tenemos una mayor cantidad de datos en años reciente en contraste a los primeros años de observación, esto en gran medida debido a la disponibilidad de imágenes satelitales. Los modelos se entrenaron utilizando el conjunto de entrenamiento y se evaluaron en el conjunto de prueba.

4.1 Línea Base

4.2 ARIMA

4.3 XGBoost

4.4 LSTM

4.5 Comparación de Resultados

Cuadro 1: Frequency of Special Characters

Modelo	MSE	Parámetros
LSTM	1 in 1,000	For Swedish names
ARIMA	1 in 5	Common in math
OLS	4 in 5	Used in business
XGB	1 in 40,000	Unexplained usage

5 Conclusiones

En este trabajo, hemos propuesto un enfoque basado en aprendizaje automático para predecir la serie de tiempo de la velocidad de deshielo de los glaciares. Encontramos que los modelos de aprendizaje automático, son herramientas valiosas para la predicción de series de tiempo en el contexto de los glaciares. Los resultados obtenidos muestran que los modelos de aprendizaje automático pueden capturar patrones temporales en la velocidad de deshielo de los glaciares y proporcionar predicciones precisas.

6 Appendices

Expresiones de gratitud

Agradecemos a la clase de la Maestría en Ciencias e Ingenierías de la Computación de la UNAM por su apoyo y orientación en este trabajo. Agradecemos al Jet Propulsion Laboratory de la NASA por proporcionar el conjunto de datos del proyecto *ITSLIVE*.

Referencias

[1] 2022. Time Series ARIMA Study of Antarctic Glacier Melting. In *Proceedings of the International Conference on Industrial Engineering and Operations Management*. IEOM Society International, Asuncion, Paraguay, 507–516. doi:10.46254/SA03.20220147

[2] Anna Derkacheva, Jeremie Mouginot, Romain Millan, Nathan Maier, and Fabien Gillet-Chaulet. 2020. Data Reduction Using Statistical and Regression Approaches for Ice Velocity Derived by Landsat-8, Sentinel-1 and Sentinel-2. *Remote Sensing* 12, 12 (June 2020), 1935. doi:10.3390/rs12121935

[3] Chad A. Greene, Alex S. Gardner, and Lauren C. Andrews. 2020. Detecting seasonal ice dynamics in satellite images. doi:10.5194/tc-2020-122

[4] Yang Lei, Alex S. Gardner, and Piyush Agram. 2021. Processing methodology for the ITS.LIVE Sentinel-1 ice velocity product. doi:10.5194/essd-2021-393

[5] Jing Zhang, Yang Lei, Laurane Charrier, Amaury Dehecq, and Alex S. Gardner. 2024. Validation of the Surface Velocity Field of Mountain Glaciers from Its.Live V2 with in Situ GPS Data. In *IGARSS 2024 - 2024 IEEE International Geoscience and Remote Sensing Symposium*. IEEE, Athens, Greece, 9–13. doi:10.1109/IGARSS53475.2024.10642917

Received 20 February 2007; revised 12 March 2009; accepted 5 June 2009