

# F-VICE: Forecasting Velocity of Ice in Glaciers Using Machine Learning

Rodrigo S. Cortez Madrigal<sup>\*\*</sup>  
rcortez@enesmorelia.unam.mx  
PCIC  
CDMX, México

Luis V. Ruiz Hernández<sup>\*\*\*</sup>  
lruiz@ciencias.unam.mx  
PCIC  
CDMX, México



Figura 1: Sermeq Kujalleq, Groenlandia, *ITS\_LIVE* de la NASA.

## Resumen

El deshielo de los glaciares es un fenómeno natural que ha aumentado en las últimas décadas debido al cambio climático. Este proceso tiene un impacto significativo en el nivel del mar y en los ecosistemas locales. En este trabajo, proponemos un enfoque basado en aprendizaje automático para predecir la serie de tiempo de la velocidad de deshielo de los glaciares. Utilizamos un conjunto de datos del proyecto *ITS\_LIVE* (Time Series of Land Ice Velocity and Elevation) del Jet Propulsion Laboratory de la NASA, que a partir de imágenes satelitales, proporciona información sobre la velocidad de deshielo de los glaciares. Finalmente comparamos los resultados de distintos modelos de aprendizaje automático y discutimos los resultados obtenidos.

## CCS Concepts

• **Do Not Use This Code → Generate the Correct Terms for Your Paper;** *Generate the Correct Terms for Your Paper;* Generate the Correct Terms for Your Paper; Generate the Correct Terms for Your Paper.

<sup>\*\*</sup>Both authors contributed equally to this research.  
<sup>\*\*\*</sup>Both authors contributed equally to this research.

Permission to make digital or hard copies of all or part of this work for personal or commercial use, or to republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from [permissions@acm.org](mailto:permissions@acm.org).  
PCIC: ML '25, Ciudad de México, México  
© 2025 Copyright held by the owner/author(s). Publication rights licensed to ACM.  
ACM ISBN 978-1-4503-XXXX-X/2025/06  
<https://doi.org/XXXXXXX.XXXXXXX>

## Palabras claves

Time Series, Machine Learning, Glaciers, *ITS\_LIVE*, ARIMA, XG-Boost, LSTM

## ACM Reference Format:

Rodrigo S. Cortez Madrigal and Luis V. Ruiz Hernández. 2025. F-VICE: Forecasting Velocity of Ice in Glaciers Using Machine Learning. In *Proceedings of Aprendizaje de Máquina (PCIC: ML '25)*. ACM, New York, NY, USA, 7 pages. <https://doi.org/XXXXXXX.XXXXXXX>

## 1 Introduction

La predicción de series de tiempo es una tarea importante en el ámbito del aprendizaje automático y la ciencia de datos. Desde la predicción de precios de acciones hasta la predicción del clima, las series de tiempo son una herramienta valiosa para la toma de decisiones y la planificación. No obstante, el estudio de series de tiempo en el contexto de los glaciares es un tema menos explorado.

El Ártico se ha calentado hasta cuatro veces más rápido que el resto del planeta durante los últimos 40 años y se prevé que las temperaturas globales se calienten aún más en las próximas décadas, lo que provocará un importante retroceso de los glaciares durante el siglo XXI [5].

Por lo tanto, es crucial comprender, analizar y predecir la velocidad de deshielo de los glaciares para mitigar sus efectos negativos. En este contexto, la modelación de series de tiempo se convierte en una herramienta esencial para predecir la velocidad de deshielo de los glaciares. No obstante, para comprender plenamente cómo responden los glaciares al cambio medioambiental se necesitarán nuevos métodos que nos ayuden a identificar el inicio de los fenómenos de aceleración del hielo y a observar cómo se propagan las señales dinámicas dentro de los glaciares [4].

En ese sentido, la velocidad de los glaciares es un parámetro importante que nos permite comprender el comportamiento dinámico

de los glaciares y su respuesta al cambio climático [9]. Estudiar la velocidad de los glaciares es crucial para comprender cómo responden al cambio climático y cómo afectan al nivel del mar.

En este trabajo, proponemos un enfoque basado en aprendizaje automático para predecir la serie de tiempo de la velocidad de deshielo de los glaciares. Utilizamos un conjunto de datos del proyecto *ITS\_LIVE* (Time Series of Land Ice Velocity and Elevation) del Jet Propulsion Laboratory de la NASA, que a partir de imágenes satelitales, proporciona información sobre la velocidad de deshielo de los glaciares. Compararemos los resultados de distintos modelos de aprendizaje automático y discutiremos los resultados obtenidos.

## 2 Antecedentes

A partir de que superar los 1,5 °C de calentamiento global por encima de los niveles preindustriales se ha convertido en un hecho cada vez más seguro, la comunidad científica ha centrado su atención en la preocupación de cambios que esto implica. No obstante, todavía no se conocen bien las consecuencias de tal superación de la temperatura global para los glaciares y su contribución al aumento del nivel del mar y a la disponibilidad de agua [8].

Por otro lado, durante la última década el número de observaciones por satélite disponibles ha aumentado considerablemente, lo que ha permitido realizar mediciones mucho más frecuentes de la velocidad de los glaciares. Proyectos como el de Intermission Time Series of Land Ice Velocity and Elevation (*ITS\_LIVE*) de la NASA aceleran la comprensión de los procesos críticos de los glaciares y las capas de hielo proporcionando a la comunidad científica registros globales, de baja latencia, exhaustivos y de última generación de las velocidades y elevaciones de la superficie observadas desde el espacio [6].

Estos datos por lo tanto permiten a través de la modelación de series de tiempo, predecir la velocidad de los glaciares y su evolución en el tiempo.

Trabajos como el de derkacheva [3] han utilizado métodos como Lowess para el estudio de estas series de tiempo, mientras que anteriormente ya se habían utilizado modelos de regresión lineal y modelos ARIMA para la predicción de series de tiempo [1] sobre otros conjuntos de datos no *ITS\_LIVE*.

## 3 Metodología

Para la predicción de la velocidad de los glaciares, utilizamos el conjunto de datos del proyecto *ITS\_LIVE* de la NASA. Este conjunto de datos contiene información sobre la velocidad de deshielo de los glaciares a partir de imágenes satelitales.

Cada observación de velocidad de deshielo de los glaciares se registra en un intervalo de tiempo específico, lo que nos permite construir una serie de tiempo. Para la modelación de series de tiempo, utilizamos distintos modelos de aprendizaje automático, incluyendo modelos de regresión lineal, modelos ARIMA y redes neuronales recurrentes (RNN).

### 3.1 Conjunto de Datos

El conjunto de datos incluye 9 glaciares y cada uno de estos tiene asociado a un DataFrame con las siguientes variables:

- *mid\_date*: Fecha media entre las dos imágenes usadas para calcular la velocidad.

- *v*: (Variable respuesta) Velocidad total de flujo (magnitud vectorial de *vx* y *vy*).
- *v\_error*: Error estimado en la velocidad total *v*.
- *vx*: Componente de velocidad en el eje X (este-oeste).
- *vx\_error*: Error en la componente de velocidad *vx*.
- *vy*: Componente de velocidad en el eje Y (norte-sur).
- *vy\_error*: Error en la componente de velocidad *vy*.
- *date\_dt*: Fecha de adquisición como objeto *datetime* completo.
- *satellite\_img1*: Nombre o código del primer satélite usado para la imagen base.
- *mission\_img1*: Misión satelital de la primera imagen.
- *x*: Coordenada X en proyección UTM u otra proyección local (EPSG específica).
- *y*: Coordenada Y en proyección UTM u otra.
- *lat*: Latitud geográfica del píxel o punto.
- *lon*: Longitud geográfica del píxel o punto.
- *year*: Año de la observación (extraído de *mid\_date*).
- *month*: Mes de la observación (extraído de *mid\_date*).
- *dayofyear*: Día del año (1 a 366).

### 3.2 Línea Base

Para establecer una línea base para la predicción de la velocidad de los glaciares, utilizamos un modelo de regresión lineal simple. Este modelo se basa en la suposición de que la velocidad de deshielo de los glaciares sigue una tendencia lineal a lo largo del tiempo. El modelo de regresión lineal se ajusta a los datos de velocidad de deshielo de los glaciares y se utiliza para predecir la velocidad futura.

Además de su simplicidad, la regresión lineal permite interpretar fácilmente la relación entre el tiempo y la velocidad del glaciar mediante sus coeficientes. El término de pendiente indica si la velocidad de flujo del glaciar está aumentando o disminuyendo con el tiempo, lo que puede ser un indicio de aceleración del deshielo por efectos climáticos. Aunque este modelo no captura patrones estacionales ni fluctuaciones no lineales, sirve como un punto de comparación robusto frente a modelos más complejos como XGBoost o ARIMA, y permite establecer una primera hipótesis sobre la evolución temporal del comportamiento glaciar.

### 3.3 ARIMA

El modelo ARIMA (Autoregressive Integrated Moving Average) es un modelo de series de tiempo que combina componentes autorregresivos, de media móvil e integración. El modelo ARIMA se utiliza para modelar series de tiempo estacionarias y no estacionarias. Para aplicar el modelo ARIMA a la serie de tiempo de la velocidad de deshielo de los glaciares, primero es necesario transformar la serie de tiempo en una serie estacionaria. Para ello, se aplican técnicas de diferenciación.

Una vez que se logra la estacionariedad mediante la diferenciación, el modelo ARIMA puede identificar y capturar patrones temporales en la serie, como la dependencia entre observaciones pasadas (componente autorregresiva, AR) y los errores de predicción previos (componente de media móvil, MA). En nuestro caso, se ajustó un modelo ARIMA a la serie temporal de velocidades de deshielo utilizando la fecha como índice temporal.

### 3.4 XGBoost

XGBoost (Extreme Gradient Boosting) es un algoritmo de aprendizaje automático basado en árboles de decisión que se ha utilizado con éxito en diversas tareas de predicción. XGBoost es un algoritmo de boosting que combina múltiples árboles de decisión para mejorar la precisión de las predicciones. Se ha utilizado en diversas aplicaciones, incluida la predicción de series de tiempo.

En el contexto de series de tiempo, aunque XGBoost no modela explícitamente la dependencia temporal como los modelos clásicos (por ejemplo, ARIMA), puede adaptarse para tareas de predicción temporal al incorporar variables que representen el tiempo, como el año, mes, día del año o rezagos de la variable objetivo. Su capacidad para capturar relaciones no lineales y manejar grandes volúmenes de datos lo convierte en una herramienta eficaz cuando se dispone de múltiples variables explicativas o características derivadas del tiempo. Además, XGBoost incluye mecanismos de regularización, lo que resulta útil cuando se trabaja con conjuntos de datos ruidosos.

### 3.5 LSTM

Las redes neuronales recurrentes (RNN) son un tipo de modelo de aprendizaje automático que se utiliza para procesar datos secuenciales, como series de tiempo. Las RNN son capaces de capturar patrones temporales en los datos y se han utilizado con éxito en diversas aplicaciones, incluida la predicción de series de tiempo. En este trabajo, utilizamos una variante de las RNN llamada LSTM (Long Short-Term Memory), que es especialmente eficaz para modelar dependencias a largo plazo en los datos.

Las redes LSTM superan una de las principales limitaciones de las RNN tradicionales: el problema del desvanecimiento o explosión del gradiente durante el entrenamiento. Gracias a su arquitectura con compuertas de entrada, olvido y salida, las LSTM pueden retener información relevante durante períodos más largos y descartar información irrelevante, lo que las hace particularmente adecuadas para modelar series de tiempo con comportamientos complejos o retardos significativos en sus patrones. En este proyecto, el modelo LSTM se alimenta con secuencias históricas de velocidad del glaciar para realizar predicciones más precisas del comportamiento futuro.

### 3.6 Comparación de Resultados

Para comparar los resultados de los distintos modelos de aprendizaje automático, utilizamos métricas de evaluación que describiremos en la siguiente subsección. Además del desempeño de los modelos, también consideramos la interpretabilidad y la complejidad de cada modelo. Este análisis comparativo nos permitirá comparar sistemáticamente el desempeño de los modelos y discutir sus fortalezas y debilidades para este problema en específico.

**3.6.1 Métricas.** Para evaluar el rendimiento de los modelos de aprendizaje automático, utilizamos métricas de evaluación como el error cuadrático medio (MSE) y el coeficiente de determinación ( $R^2$ ).

- El error cuadrático medio (MSE) es una métrica que mide la diferencia entre los valores predichos por el modelo y los valores reales de la variable objetivo. El MSE se calcula como la media de los cuadrados de las diferencias entre los valores predichos y los valores reales.


- RMSE es la raíz cuadrada del MSE, lo que nos da una medida de error en las mismas unidades que la variable objetivo. Es útil porque nos permite interpretar el error en términos de la variable objetivo y compararlo con los valores reales. Elegimos el RMSE para este problema en específico porque en el contexto de la predicción de series de tiempo, es importante minimizar los errores grandes para obtener predicciones más precisas.
- El coeficiente de determinación ( $R^2$ ) es una métrica que mide la proporción de la varianza de la variable objetivo que es explicada por el modelo. El  $R^2$  se calcula como la proporción de la varianza de los valores predichos que es explicada por la varianza de los valores reales. Es útil porque nos permite evaluar la capacidad del modelo para explicar la variabilidad de los datos.

## 4 Experimentos y Resultados

Para evaluar el rendimiento de los modelos de aprendizaje automático, realizamos una serie de experimentos utilizando el conjunto de datos del proyecto *ITS\_LIVE* de la NASA. Seleccionamos un subconjunto de glaciares importantes y obtuvimos las series de tiempo de la velocidad de deshielo de estos glaciares. El conjunto de datos se dividió en un conjunto de entrenamiento y un conjunto de prueba en un porcentaje de 70 % para entrenamiento y 30 % para prueba. Esto debido a que tenemos un mayor cantidad de datos en años recientes en contraste a los primeros años de observación, esto en gran medida debido a la disponibilidad de imágenes satelitales. Los modelos se entrenaron utilizando el conjunto de entrenamiento y se evaluaron en el conjunto de prueba.

### 4.1 Línea Base

Espectro de frecuencias de la serie temporal



**Figura 2: Transformada de Fourier de la serie de tiempo de la velocidad del glaciar Sermeq Kujalleq en Groenlandia.**

*Estacionalidad.* En varios de nuestros gráficos, vemos que los datos tienen un elemento estacional. Intuitivamente, sabemos que

los datos de la velocidad del glaciar también deberían tener un componente estacional. La velocidad del glaciar debería oscilar cada año, más alta en verano y más baja en invierno. Para validar estas sospechas, podemos fijarnos en las transformadas de Fourier de nuestras series. Las transformadas de Fourier nos permiten convertir una serie basada en la amplitud en una serie basada en la frecuencia. Son funciones de valor complejo que representan cada serie como una superposición de ondas sinusoidales en un plano complejo.

Dado que en la Fig. 2 hay un pico claro cerca de la frecuencia 0.0027 (1/365), eso indica estacionalidad anual.

*Estacionariedad.* Una serie temporal es estacionaria cuando sus propiedades estadísticas como la media, la varianza y la autocorrelación no cambian con el tiempo. Métodos como ARIMA y sus variantes funcionan bajo el supuesto de que la serie temporal que modelizan es estacionaria. Si la serie temporal no es estacionaria, estos métodos no funcionan muy bien.

Utilizamos la prueba de Dickey-Fuller aumentada (ADF) y la prueba de Kwiatkowski-Phillips-Schmidt-Shin (KPSS) para verificar la estacionariedad de nuestras series temporales. Encontramos que la mayoría de nuestras series temporales no son estacionarias, lo que significa que tienen una tendencia o una varianza que cambia con el tiempo.

Lo que sugiere que modelos como ARIMA y sus variantes no funcionarán bien con nuestras series temporales sin una transformación previa.

*OLS.* Para establecer una línea base, utilizamos un modelo de regresión lineal simple (OLS) para predecir la velocidad de los glaciares.

Obtuvimos los siguientes resultados para el modelo OLS




Figura 3: Predicciones del modelo OLS para el glaciar Jakobshavn.

*Normalidad de los residuales.* Para verificar la normalidad de los residuales del modelo OLS, utilizamos los siguientes tests.

- **Jarque-Bera:** p-value = 0,0
- **Shapiro-Wilk:** p-value =  $9,27 \times 10^{-40}$
- **Kolmogorov-Smirnov:** p-value = 0,0

Estos resultados indican que los residuales del modelo OLS no siguen una distribución normal, lo que sugiere que el modelo OLS no es adecuado para predecir la velocidad de los glaciares.

*Heterocedasticidad.* La heterocedasticidad es un problema común en los modelos de regresión lineal, donde la varianza de los errores no es constante a lo largo de las observaciones. Para verificar la heterocedasticidad de los residuales del modelo OLS, utilizamos los siguientes tests.

- **Breusch-Pagan:** p-value =  $6,58 \times 10^{-5}$
- **White:** p-value =  $4,69 \times 10^{-8}$

Estos resultados indican que los residuales del modelo OLS presentan heterocedasticidad, lo que significa que la varianza de los errores no es constante a lo largo de las observaciones.

*Resultados del modelo OLS.* Los resultados del modelo OLS se muestran en la Figura 3 y en la Tabla 1.

Cuadro 1: Resultados del modelo OLS

| Métrica    | Valor        |
|------------|--------------|
| MA         | 1698.99      |
| MSE        | 3 468 429.84 |
| RMSE       | 1 862.37     |
| $R^2$      | 0.400        |
| Adj. $R^2$ | 0.399        |

A pesar de que el modelo OLS tiene un  $R^2$  de 0,4, lo que indica que el modelo explica el 40 % de la varianza de los datos, los resultados no son muy buenos, ya que el RMSE es de 1862,37, lo que indica que el modelo tiene un error cuadrático medio alto. Esperábamos que el modelo OLS no funcionara muy bien debido a los criterios de estacionariedad y normalidad que revisamos anteriormente. No obstante, el modelo OLS sirve como una línea base para comparar los resultados de los otros modelos de aprendizaje automático. Adicionalmente podemos observar una tendencia creciente en la serie temporal, lo que indica que la velocidad de los glaciares está aumentando con el tiempo.

4.2 ARIMA

A continuación se presenta la gráfica obtenida al aplicar un modelo  $ARIMA(p = 9, d = 1, q = 2)$  cuyos parámetros representan

- p: Número de retardos autorregresivos (AR).
- d: Número de diferencias necesarias para hacer la serie estacionaria.
- q: Número de términos de media móvil (MA)

a los datos del glaciar Alaska-Columbia Glacier






Figura 4: Predicciones del modelo ARIMA para el glaciar Jakobshavn

Podemos observar que la serie parece tener ciclos anuales o multianuales bien definidos sin embargo el modelo no sigue del todo estas oscilaciones, indicando que el modelo tiene limitaciones para capturar esta estacionalidad. Esto lo podemos ver en la línea azul que representa las predicciones en el conjunto de prueba.

Por otro lado las predicciones a futuro que realiza el modelo son constantes, lo que significa que

- El modelo ya no tiene nueva estructura que extrapolar.
- Asume que la última tendencia o nivel es estacionario.

A continuación se muestra una tabla con las métricas de evaluación del modelo

Cuadro 2: Resultados del modelo ARIMA

| Métrica    | Valor     |
|------------|-----------|
| MAE        | 5,416.85  |
| MSE        | 3,293,357 |
| RMSE       | 5,738.77  |
| $R^2$      | -0.788    |
| Adj. $R^2$ | -0.796    |

El modelo ARIMA mostró limitaciones importantes debido a la naturaleza no estacionaria y estacional de la serie de tiempo ya que realiza un trabajo de ajuste y predicción muy malo, que se traduce en un MSE es muy alto, debido además a la presencia de ruido satelital (outliers), además el  $R^2$  negativo indica que el modelo predice mucho peor que seleccionar el valor medio de los datos.

A pesar de aplicar una diferenciación de orden uno, los resultados sugieren que la serie aún no era estacionaria, lo cual compromete la validez de los supuestos de ARIMA. Además, la estacionalidad no pudo ser capturada adecuadamente por un modelo ARIMA estándar, lo que resultó en predicciones planas y métricas de desempeño pobres ( $R^2 < 0$ ).

### 4.3 XGBoost

Para el modelo XGBoost, tuvimos que utilizar características adicionales. Estas características incluyen el año, mes, día del año, lags, rolling windows y diferencias de la variable objetivo. Adicionalmente, utilizamos GridSearchCV de Scikit-learn [7] para encontrar los mejores hiperparámetros del modelo XGBoost los cuales se muestran en la Tabla 3.

Cuadro 3: Mejores hiperparámetros del modelo XGBoost

| Hiperparámetro   | Valor |
|------------------|-------|
| colsample_bytree | 0.7   |
| learning_rate    | 0.1   |
| max_depth        | 3     |
| n_estimators     | 1000  |
| subsample        | 0.7   |

Los resultados obtenidos con el modelo que se muestra en la Figura 5 son bastante buenos, ya que el modelo logra capturar la estacionalidad de la serie de tiempo y las predicciones son más precisas que las del modelo OLS y ARIMA. No obstante, para predicciones futuras fuera del rango de datos de entrenamiento, el modelo XGBoost no extrapola bien. Esto en mayor medida debido a que el modelo no captura la estructura temporal de la serie de tiempo, sino que se basa en las características adicionales que le proporcionamos.

Cuadro 4: Resultados del modelo XGBoost

| Métrica    | Valor     |
|------------|-----------|
| MAE        | 112.34    |
| MSE        | 177600.20 |
| RMSE       | 421.43    |
| $R^2$      | 0.9547    |
| Adj. $R^2$ | 0.9546    |




Figura 5: Predicciones del modelo XGBoost para el glaciar Jakobshavn.

### 4.4 LSTM

Para el modelo LSTM, utilizamos una arquitectura de red neuronal recurrente con capas LSTM. El modelo LSTM utilizado consiste en dos capas LSTM bidireccionales con 64 unidades ocultas, seguidas de una capa densa y con un total de 145537 parámetros. El modelo fue implementado utilizando Pytorch [2] y se entrenó durante 30 épocas usando el optimizador Adam y la función de pérdida MSE, aplicando scheduled sampling para mejorar la generalización. Para la preparación de los datos de entrenamiento, se

generaron características adicionales a partir de las columnas de fecha y la variable objetivo, como rezagos (lags), medias móviles y codificación estacional con funciones seno y coseno del día del año. Posteriormente, los datos se dividieron en conjuntos de entrenamiento y prueba (70 % y 30 % respectivamente). Además los datos se normalizaron utilizando el StandardScaler de Scikit-learn para que las características tuvieran media cero y desviación estándar uno, lo que es crucial para el buen funcionamiento de las redes neuronales. Finalmente, se transformaron en secuencias para alimentar el modelo LSTM, permitiendo capturar dependencias temporales y patrones estacionales en la serie de tiempo. Esto es especialmente importante en las redes LSTM, ya que están diseñadas para manejar datos secuenciales y aprender de las relaciones temporales en los datos.




Figura 6: Predicciones del modelo LSTM para el glaciar Jakobshavn.

Obtuvimos buenos resultados con el modelo LSTM, ya que el modelo logra capturar la estacionalidad de la serie de tiempo y las predicciones son más precisas que las del modelo OLS y ARIMA. No obstante, al igual que con el modelo XGBoost, el modelo LSTM no extrapola bien para predicciones futuras fuera del rango de datos de entrenamiento. Sin embargo el modelo LSTM logra capturar la estructura temporal de la serie de tiempo y la tendencia de aumento de la velocidad de deshielo de los glaciares.

Cuadro 5: Resultados del modelo LSTM

| Métrica    | Valor     |
|------------|-----------|
| MAE        | 218.40    |
| MSE        | 136648.44 |
| RMSE       | 369.66    |
| $R^2$      | 0.9625    |
| Adj. $R^2$ | 0.9622    |

4.5 Discusión

Los resultados obtenidos con los distintos modelos de aprendizaje automático muestran que los modelos de aprendizaje automático son capaces de capturar la estacionalidad y la tendencia de aumento de la velocidad de deshielo de los glaciares. El modelo OLS, aunque simple, sirve como una línea base y muestra que la velocidad de

deshielo de los glaciares tiene una tendencia creciente. El modelo ARIMA, aunque conceptualmente apropiado para datos temporales, no logró capturar adecuadamente la estructura estacional de los glaciares y sus predicciones fueron planas, lo que sugiere que su aplicabilidad directa es limitada para series con estacionalidad y ruido como las de ITS\_LIVE. El modelo XGBoost demostró gran capacidad predictiva al incorporar variables derivadas del tiempo (lags, rolling, mes, año, etc.), lo que compensó su incapacidad nativa para modelar secuencias. El modelo LSTM, al aprovechar su arquitectura de memoria, fue el modelo más preciso, mostrando gran potencial para modelar dependencias de largo plazo en los glaciares. Es importante notar que a pesar de que utilizar features adicionales, esto implica que las predicciones futuras (a manera autorregresiva) no son extrapolables.

Se trata de un problema complejo, ya que la velocidad de deshielo de los glaciares es un fenómeno natural que está influenciado por muchos factores, como el clima, la topografía y la geología. Los datos que utilizamos son limitados y no contienen toda la información necesaria para predecir la velocidad de deshielo de los glaciares mas allá de la temporalidad. Este trabajo podria ser indudablemente mejorado con la incorporación de datos adicionales como datos climáticos. No obstante, los resultados obtenidos consideramos que los resultados obtenidos son satisfactorios ya que muestras que los modelos de aprendizaje automatico pueden ser útiles para esta tarea.

5 Conclusiones

En este trabajo, hemos propuesto un enfoque basado en aprendizaje automático para predecir la serie de tiempo de la velocidad de deshielo de los glaciares, permitiendonos concluir para cada modelo lo siguiente:

- La regresión lineal (OLS) mostró una capacidad limitada de ajuste, pero su simplicidad permite una interpretación directa de tendencias, sirviendo como línea base.
- El modelo ARIMA, si bien conceptualmente apropiado para datos temporales, no logró capturar adecuadamente la estructura estacional de los glaciares. Las métricas de desempeño ( $R^2$  negativo) y las predicciones planas sugieren que su aplicabilidad directa es limitada para series con estacionalidad y ruido como las de ITS\_LIVE.
- XGBoost demostró gran capacidad predictiva ( $R^2 \approx 0,95$ ) al incorporar variables derivadas del tiempo (lags, rolling, mes, año, etc.), lo que compensó su incapacidad nativa para modelar secuencias.
- LSTM, al aprovechar su arquitectura de memoria, fue el modelo más preciso ( $R^2 > 0,96$ ), mostrando gran potencial para modelar dependencias de largo plazo en los glaciares.

Encontramos que los modelos de aprendizaje automático, son herramientas valiosas para la predicción de series de tiempo en el contexto de los glaciares ya que los resultados obtenidos muestran que estos pueden capturar patrones temporales en la velocidad de deshielo de los glaciares y proporcionar predicciones precisas.

En resumen, los resultados sugieren que los modelos de aprendizaje automático superan significativamente a los modelos clásicos en esta tarea, especialmente cuando se combinan con un buen diseño de variables y preprocesamiento. Para futuros experimentos

se podrían explorar modelos híbridos (SARIMA-LSTM, DeepAR) y aplicar explicabilidad (SHAP, LRP) para entender las contribuciones temporales y estacionales a la predicción.

## 6 Appendices

### Expresiones de gratitud

Agradecemos a la clase de la Maestría en Ciencias e Ingenierías de la Computación de la UNAM por su apoyo y orientación en este trabajo. Agradecemos al Jet Propulsion Laboratory de la NASA por proporcionar el conjunto de datos del proyecto *ITS\_LIVE*.

### Referencias

- [1] 2022. Time Series ARIMA Study of Antarctic Glacier Melting. In *Proceedings of the International Conference on Industrial Engineering and Operations Management*. IEOM Society International, Asuncion, Paraguay, 507–516. doi:10.46254/SA03.20220147
- [2] Jason Ansel, Edward Yang, Horace He, Natalia Gimelshein, Animesh Jain, Michael Voznesensky, Bin Bao, Peter Bell, David Berard, Evgeni Burovski, Geeta Chauhan, Anjali Chourdia, Will Constable, Alban Desmaison, Zachary DeVito, Elias Ellison, Will Feng, Jiong Gong, Michael Gschwind, Brian Hirsh, Sherlock Huang, Kshiteej Kalambarkar, Laurent Kirsch, Michael Lazos, Mario Lezcano, Yanbo Liang, Jason Liang, Yinghai Lu, CK Luk, Bert Maher, Yunjie Pan, Christian Puhersch, Matthias Reso, Mark Saroufim, Marcos Yukio Siraichi, Helen Suk, Michael Suo, Phil Tillet, Eikan Wang, Xiaodong Wang, William Wen, Shunting Zhang, Xu Zhao, Keren Zhou, Richard Zou, Ajit Mathews, Gregory Chanan, Peng Wu, and Soumith Chintala. 2024. PyTorch 2: Faster Machine Learning Through Dynamic Python Bytecode Transformation and Graph Compilation. In *29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2 (ASPLOS '24)*. ACM. doi:10.1145/3620665.3640366
- [3] Anna Derkacheva, Jeremie Mouginot, Romain Millan, Nathan Maier, and Fabien Gillet-Chaulet. 2020. Data Reduction Using Statistical and Regression Approaches for Ice Velocity Derived by Landsat-8, Sentinel-1 and Sentinel-2. *Remote Sensing* 12, 12 (June 2020), 1935. doi:10.3390/rs12121935
- [4] Chad A. Greene, Alex S. Gardner, and Lauren C. Andrews. 2020. Detecting seasonal ice dynamics in satellite images. doi:10.5194/tc-2020-122
- [5] Jan Kavan, Malgorzata Szczypińska, William Kochtitzky, Louise Farquharson, Mette Bendixen, and Mateusz C. Strzelecki. 2025. New coasts emerging from the retreat of Northern Hemisphere marine-terminating glaciers in the twenty-first century. *Nature Climate Change* 15, 5 (May 2025), 528–537. doi:10.1038/s41558-025-02282-5
- [6] Yang Lei, Alex S. Gardner, and Piyush Agram. 2021. Processing methodology for the ITS\_LIVE Sentinel-1 ice velocity product. doi:10.5194/essd-2021-393
- [7] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. 2011. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* 12 (2011), 2825–2830. <https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html>
- [8] Lilian Schuster, Fabien Maussion, David R. Rounce, Lizz Ultee, Patrick Schmitt, Fabrice Lacroix, Thomas L. Frölicher, and Carl-Friedrich Schleussner. 2025. Irreversible glacier change and trough water for centuries after overshooting 1.5 °C. *Nature Climate Change* (May 2025). doi:10.1038/s41558-025-02318-w
- [9] Jing Zhang, Yang Lei, Laurane Charrier, Amaury Dehecq, and Alex S. Gardner. 2024. Validation of the Surface Velocity Field of Mountain Glaciers from Its\_Live V2 with in Situ GPS Data. In *IGARSS 2024 - 2024 IEEE International Geoscience and Remote Sensing Symposium*. IEEE, Athens, Greece, 9–13. doi:10.1109/IGARSS53475.2024.10642917

Received 20 February 2007; revised 12 March 2009; accepted 5 June 2009